

AndinaRetail S.A.C.

GRUPO 04 · INTEGRANTES Y ROLES

Guzmán Neyra, Paulo Renato

Analista Estadístico / Descriptivo

Huerta Firma, Freddy Anthony

Analista de Optimización / BI

Justino Ocmin, Jhamir Valeri

Científico de Datos

Mendoza Meza, Pablo Andrés

Ingeniero de Datos

Rodas Panaifo, Jordan André

Analista de Optimización / BI

Sánchez Saldaña, Sergio Antonio

Líder del Proyecto / Data PM

ENLACE: https://github.com/SergIOSanchez99/proyecto_AndinaRetail_G4.git

Agenda

1

Contexto y Objetivos

Situación de negocio de AndinaRetail y alcance de las cinco fases analíticas.

2

Herramientas y Metodología

Ecosistema de desarrollo, control de versiones y uso de IA generativa.

3

Fase 1 — Ingeniería de Datos

Generación, integridad y control de calidad del dataset sintético.

4

Fase 2 y 3 — Análisis Estadístico

Pruebas de hipótesis, series de tiempo, Pareto y segmentación de clientes.

5

Fase 4 — Modelado Predictivo

Regresión de demanda y clasificación de respuesta a campañas.

6

Fase 5 — Optimización Prescriptiva

Formulación matemática (PuLP) y simulación bajo incertidumbre.

7

Conclusiones y Recomendaciones

Hallazgos clave y lineamientos estratégicos para la gerencia.

Contexto de Negocio y Objetivos

CONTEXTO EMPRESARIAL

- 1 Empresa peruana omnicanal**
AndinaRetail S.A.C. opera tiendas físicas y canal digital (Web y App) con presencia en Lima, Arequipa, Trujillo, Cusco y Piura.
- 2 Desafíos de rentabilidad**
Se detectó una caída atípica de margen en Trujillo desde 2025-Q2 que requiere un diagnóstico causa-raíz urgente.
- 3 Retención y fuga de clientes**
La gerencia observa un nivel relevante de inactividad de clientes y requiere segmentación y retención dirigida.

OBJETIVO GENERAL DE LA DEFENSA

- 1 Fase 1 — Ingeniería y calidad de datos**
Asegurar consistencia, integridad referencial y control de nulos/outliers en el dataset sintético de ventas.
- 2 Fase 2 y 3 — Análisis estadístico**
Pruebas de hipótesis, series de tiempo, Pareto y segmentación RFM + K-Means.
- 3 Fase 4 — Modelado predictivo**
Regresión para demanda y clasificación de respuesta a campañas, evitando data leakage.
- 4 Fase 5 — Optimización prescriptiva**
Políticas óptimas de reabastecimiento con PuLP, validadas bajo incertidumbre (Monte Carlo).

Herramientas y Ecosistema de Desarrollo

ECOSISTEMA DE DESARROLLO Y CONTROL

1

Git & GitHub

Control de versiones local con Git y alojamiento del repositorio en GitHub, facilitando la colaboración, integración de ramas y respaldo del código.

2

Jupyter Notebooks y Collab

Entornos de desarrollo basados en web que permiten estructurar interactivamente las cinco fases del análisis de datos. Su arquitectura por "celdas" facilita la ejecución modular del código, permitiendo depurar y ver resultados al instante sin reiniciar todo el flujo.

3

Librerías de código abierto

pandas/numpy para limpieza de datos, scipy para contraste de hipótesis, scikit-learn/lightgbm para modelado y PuLP para optimización lineal.

METODOLOGÍA E IA GENERATIVA

1

IA generativa en el flujo de trabajo

Co-programación interactiva apoyada en modelos de lenguaje (Claude, ChatGPT, Gemini) para la generación rápida de código base y depuración.

2

Bitácora de prompts

Registro y documentación detallada de cada prompt utilizado, almacenado en docs/bitacora_prompts.md para garantizar reproducibilidad.

3

Ingeniería de prompts

Diseño de instrucciones estructuradas para simular patrones comerciales complejos, evitar fugas de información temporal y calibrar hiperparámetros.

Ingeniería de Datos y Calidad

FLUJO DE DATOS Y GENERACIÓN

- 1 Script generar_datos.py**
Código Python con semillas fijas (2026) que produce datos coherentes y reproducibles usando Faker (es_PE).
- 2 Volúmenes del ecosistema**
Clientes (15k), productos (800–1000), tiendas (12), ventas (~250k líneas) e inventario mensual (~345k–432k snapshots).
- 3 Filtros e integridad**
Modelamiento a nivel de ticket y línea de venta, con validación automática de llaves foráneas mediante aserciones en el script.

DIAGNÓSTICO DE CALIDAD DE DATOS

- 1 Tratamiento de nulos (1%–3%)**
Campos como método de pago, % de descuento, canal preferido y distrito contienen nulos controlados con patrones validados.
- 2 Detección de outliers**
Outliers en cantidad y % de descuento detectados mediante el método IQR y validados sin romper la coherencia matemática.
- 3 Reglas de consistencia**
Validación de $\text{monto_total} = \text{cantidad} \times \text{precio} \times (1 - \text{descuento})$ y del balance de inventario ($\text{stock final} = \text{inicial} - \text{ventas} + \text{reabastecimiento}$).

Análisis Estadístico Descriptivo

ESTADÍSTICA DESCRIPTIVA Y OUTLIERS

- 1 Distribuciones sesgadas**
monto_total y cantidad presentan distribuciones no normales (skewness del monto = 8.89), habitual en retail por productos de alto valor.
- 2 Filtro de outliers (IQR)**
Las transacciones con cantidad o monto atípico corresponden a compras legítimas en Electrohogar, no a errores de registro.
- 3 Consistencia interna**
Se confirmó la correlación directa entre descuento y cantidad comprada, y la consistencia de los precios unitarios.

PRUEBA DE HIPÓTESIS: TICKET POR CANAL

- 1 Formulación de hipótesis**
H0: ticket promedio igual en Tienda y Web. H1: son diferentes. Evaluada con t-test de Welch por heterocedasticidad (Levene, $p < 0.0001$).
- 2 Rechazo de H0 con alta confianza**
Diferencia significativa (Welch $t = -16.67$, $p < 0.000001$): el ticket promedio en Web es mayor.
- 3 Violación del supuesto de normalidad**
Shapiro fue rechazado ($p \approx 0$), pero el Teorema del Límite Central y el gran tamaño de muestra ($N > 200k$) sostienen la validez de la inferencia.

S/ 571

TICKET PROMEDIO · WEB

S/ 464

TICKET PROMEDIO · TIENDA

Estacionalidad y Evolución del Canal Digital

ESTACIONALIDAD Y CAMPAÑAS

1

Picos mensuales claros

Las ventas agregadas muestran un patrón estacional estable, con picos máximos en julio (Fiestas Patrias) y diciembre (Navidad).

2

Crecimiento progresivo

Estabilidad de la línea base en meses normales, con incrementos previsibles año tras año.

3

Implicancias de abastecimiento

La concentración de ventas exige planificar reabastecimiento y promociones con al menos 60 días de anticipación.

EVOLUCIÓN DIGITAL VS. FÍSICO

1

Penetración del canal digital


Crecimiento sistemático anual (~10 puntos porcentuales de participación por año).

2

Hito del año 2025

El canal digital superó por primera vez al físico, con el 55.1% de la venta total.

Participación de Venta — Canal Digital (%)



Pareto y Segmentación de Clientes

CONCENTRACIÓN DE VENTAS (PARETO 80/20)

1


Concentración de productos

El 17.8% de los productos (142 de 800) genera el 80% de las ventas; la mayoría pertenece a Electrohogar.

2

Amplia base de clientes

El 45.2% de los clientes genera el 80% del valor: no hay dependencia de pocos clientes VIP, la base es democrática.



SEGMENTACIÓN RFM MANUAL

1

Segmento Campeones (24.8%)

Clientes de alta frecuencia y gasto, con ticket histórico promedio de S/ 17,645. Motor financiero principal del negocio.

2

Riesgo crítico de fuga

El segmento Hibernando / Perdidos representa el 35.3% de la base, con una recencia promedio de 253 días.

3

Clientes 'No Perder' y 'En Riesgo' (4.8%)

Clientes de alto valor histórico pero alta recencia: foco principal de las campañas de CRM.

24.8%
CAMPEONES

35.3%
FUGA (RFM)

4.8%
EN RIESGO

Validación de Segmentos con K-Means

CLUSTERING NO SUPERVISADO

- 1

Determinación de k óptimo

El método del codo confirmó que k = 4 clusters representa de forma óptima la varianza de los datos RFM estandarizados.
- 2

Validación de la segmentación

La progresión de valores promedio de los clusters (de alto valor a inactivos) coincide matemáticamente con los perfiles del RFM manual.
- 3

Aplicación práctica

Permite automatizar en producción la asignación de ofertas personalizadas según el cluster asignado dinámicamente.
- 4

Consistencia con el RFM manual

Se valida la alta coincidencia operativa: los clusters capturan con precisión a los 'Campeones' y a los 'Hibernando' del RFM manual.

PERFIL DE LOS CLUSTERS OBTENIDOS

Cluster / Perfil	N Clientes	Recencia	Frec.	Gasto Med.
Alto Valor, Activo	2,491	13.7 días	34.7	S/ 21,817
Valor Medio, Activo	4,895	36.4 días	20.8	S/ 9,933
Bajo Valor, Inactivo	6,227	131.4 días	9.1	S/ 3,543
Perdido / Crítico	1,282	504.1 días	3.9	S/ 1,917

- 1


Consistencia estadística

Se valida la alta coincidencia operativa: los clusters capturan con precisión a los 'Campeones' y a los 'Hibernando' del RFM manual.

Causa Raíz: Caída de Margen en Trujillo

IDENTIFICACIÓN DEL PROBLEMA

- 1 Caída de margen en Trujillo**
A partir de 2025-Q2, el margen en Trujillo se desploma de 24.33% a 13.86% (–10.5 puntos).
- 2 Estabilidad en otras plazas**
Lima, Cusco, Arequipa y Piura no muestran variación en sus márgenes (~23–24%) en el mismo periodo.
- 3 Ventas con margen negativo**
De 209 líneas de venta con margen negativo en todo el país, 169 (81%) pertenecen a Trujillo en 2025.



DESCOMPOSICIÓN DE LA CAUSA RAÍZ

- 1 Incremento del descuento promedio**
En Trujillo el descuento promedio se triplicó, de 5.69% a 16.85%: evidencia de una política comercial agresiva y descontrolada.
- 2 Incremento de costos logísticos**
El costo de almacenamiento unitario por producto-tienda casi se duplicó, de S/ 0.30 a S/ 0.56, inflando el holding cost.
- 3 Recomendaciones inmediatas**
Corregir la política de descuentos (alinear a la media de 7%) y optimizar los stocks locales para reducir el holding cost.

16.85%

DESCUENTO PROM. TRUJILLO

S/ 0.56

COSTO ALMACÉN UNITARIO

Regresión de Demanda

FORMULACIÓN Y ENTRENAMIENTO

- 1 Objetivo del modelo**
Predecir la cantidad de unidades demandadas (demanda mensual) por producto, canal y campaña comercial.
- 2 Estrategia temporal (sin leakage)**
Construcción de variables históricas: 2023 como antecedente, 2024 para entrenamiento y 2025 reservado estrictamente para test final.
- 3 Validación cruzada (4 folds)**
CV temporal con ventana expansiva, asegurando que datos futuros no validen datos pasados.

MODELO SELECCIONADO Y DESEMPEÑO

- 1 Modelo ganador: Random Forest**
Menor MAE promedio en validación cruzada (3.45) y excelente generalización en el conjunto de prueba 2025.
- 2 Comparativa de modelos**
XGBoost fue competitivo (MAE 3.25, R^2 0.69). Ridge tuvo bajo desempeño y arrojó 457 predicciones negativas, inviables en stock.
- 3 Drivers clave (SHAP / importancia)**
La demanda de la misma campaña del año anterior explicó el 63.98% de la importancia, seguida por canal, descuento y categoría.

3.18 uds.

MAE EN TEST 2025

0.7089

R^2 EN TEST 2025

Respuesta a Campañas Comerciales

FORMULACIÓN Y PREPROCESAMIENTO

- 1 Objetivo del modelo**
Predecir si un cliente realizará al menos una compra (1) o no (0) durante una campaña específica.
- 2 Población elegible**
Solo clientes registrados antes del inicio de la campaña evaluada. Unidad de análisis: cliente-campaña.
- 3 Preprocesamiento y folds (3)**
One-Hot Encoding, SMOTETomek para el desbalance de clases, y 3 folds temporales expansivos en 2024.

MODELO SELECCIONADO Y DESEMPEÑO

- 1 Modelo ganador: Extra Trees**
Seleccionado por el mejor F1 promedio en CV (0.3118) y menor costo computacional frente a ensamblés tradicionales.
- 2 Drivers de la decisión (SHAP)**
Las variables más importantes fueron el mes de la campaña (fuerte peso en diciembre/Navidad) y la recencia del cliente.
- 3 Valor de negocio**
Especificidad de 92.96% en prueba 2025: ideal para excluir con seguridad a los no compradores y ahorrar costos de contacto.

0.2863

F1 EN TEST 2025

84.17%

ACCURACY TEST

92.96%

ESPECIFICIDAD TEST


Modelo Prescriptivo y Optimización

FORMULACIÓN MATEMÁTICA (PULP)

- 1 Variables de decisión**
 $Q(p,t)$: cantidad de reabastecimiento; $E(p,t)$: stock final (holding); $U(p,t)$: ventas insatisfechas (unmet demand).
- 2 Función objetivo**
Minimizar el costo total = holding cost ($h \cdot E$) + penalización por faltantes ($\text{penalty} \cdot U$) + costo de compras ($c \cdot Q$).
- 3 Restricciones clave**
Balance de flujo de stock, presupuesto máximo de compras (P_{budget}) y límites de capacidad.

ESCENARIOS Y SIMULACIÓN MONTE CARLO

- 1 Sensibilidad de presupuesto y simulación**
El análisis de sensibilidad mostró un costo total constante (S/ 40,768.02) entre presupuestos. Se validó además con 100 escenarios Monte Carlo (demanda Poisson), comparando el LP optimizado frente a una heurística del 10%.
- 2 Ventaja del modelo optimizador**
El LP logró un ahorro de ~8% en holding frente a la heurística, manteniendo el nivel de servicio.




~8% ahorro
EN COSTO DE ALMACENAMIENTO

0.040 uds.
DEMANDA NO SATISFECHA

Modelo de datos implementado

Estructura tipo estrella para evitar duplicidades y filtros ambiguos



Tablas principales

FactVentas: líneas de venta por ticket.

FactInventario: stock mensual producto-tienda.

DimClientes, DimProductos y DimTiendas.

DimFecha marcada como tabla calendario.

Relaciones

Cardinalidad 1:* desde dimensiones a hechos.

Filtro cruzado en dirección única.

Fecha relacionada con ventas e inventario.

Sin relaciones directas entre tablas de hechos.

Resultado

El modelo permite filtrar ventas, margen e inventario por tiempo, ciudad, categoría, canal y cliente sin duplicar totales.

Indicadores y medidas DAX

KPI calculados para ventas, margen, clientes e inventario

S/ 325.3 M

Ventas Totales

S/ 63.1 M

Margen Total

19.40 %

Margen %

100 mil

Tickets

58.15 %

Tasa de inactividad

Medidas representativas

```
Ventas Totales = SUM(FactVentas[moneto_total])
```

```
Margen % = DIVIDE([Margen Total], [Ventas Totales], 0)
```

```
Ticket Promedio = DIVIDE([Ventas Totales], [Total Tickets], 0)
```

```
Tasa de Inactividad = DIVIDE([Clientes Inactivos], [Total Clientes], 0)
```

Por qué medidas y no columnas estáticas


Se recalculan según filtros de año, ciudad, categoría y canal.
Permiten comparar páginas sin duplicar lógica.
Facilitan control de formatos: moneda, porcentaje y enteros.
Separan el cálculo del diseño visual.

Validación

Antes de diseñar las páginas finales se creó una página temporal de validación para comprobar que las tarjetas reaccionaran a los segmentadores.

Página 1: tablero ejecutivo

Visión general del desempeño comercial y de clientes



Lectura gerencial

Ventas acumuladas: S/ 325.3 millones.
Margen acumulado: S/ 63.1 millones.
Margen porcentual: 19.40 %.
Ticket promedio: S/ 3.25 mil.
Tasa de inactividad: 58.15 %.

Objetivo de la página


Permitir que la gerencia identifique en una sola vista el estado comercial, la rentabilidad y el riesgo de clientes antes de profundizar en análisis específicos.

Alerta ejecutiva

La principal señal de riesgo es la inactividad de clientes. Por ello, las páginas siguientes profundizan en ventas, margen y segmentación.

Página 2: análisis de ventas y margen

Desglose por ciudad, categoría, canal y periodo



Qué responde esta página

- ¿Dónde se concentran ventas y margen?
- ¿Qué categorías lideran el resultado?
- ¿Cómo evolucionan Tienda, Web y App?
- ¿Qué relación existe entre descuento y margen?

Interacción clave

El marcador “Alerta Trujillo 2025” permite enfocar la lectura en la plaza y periodo donde se requiere revisar la política de descuentos.

Decisión sugerida

Monitorear ciudades con mayor descuento promedio y revisar su impacto en margen porcentual antes de intensificar promociones.

Página 3: clientes, RFM y churn

Actividad, valor y riesgo de inactividad

15 mil

Total clientes

6.3 mil

Clientes activos

8.7 mil

Clientes inactivos

58.15 %

Tasa de inactividad

S/ 21.7 mil

Valor promedio

Segmentos principales

Inactivo: 8,723 clientes.
Regular: 2,616 clientes.
Alto Valor: 2,601 clientes.
Frecuente y Ocasional: menor volumen.

Perfil RFM resumido

Alto Valor
Recencia: 16.9 días
Frecuencia: 14.8 tickets
Valor prom.: S/ 52.9 mil

Inactivo
Recencia: 384.3 días
Frecuencia: 3.9 tickets
Valor prom.: S/ 12.4 mil

Hallazgo de clientes

El segmento inactivo concentra la mayor alerta. Los clientes de Alto Valor tienen menor recencia y mayor frecuencia, por lo que deben preservarse con estrategias de fidelización.

Interactividad implementada

Del análisis general al detalle operativo

1

Segmentadores

Año, ciudad, categoría, canal y campaña para filtrar los KPI y gráficos.

2

Drill-down

Jerarquía temporal Año → Trimestre → Mes para analizar evolución.

3

Drill-through

Página Detalle_Ciudad para profundizar en una plaza seleccionada.

4


Navegación

Navegador de páginas para moverse entre las vistas principales.

5

Bookmarks

Vista general y Alerta Trujillo 2025 para acelerar la lectura.



Ejemplo: filtros y vista de ventas

Valor para el usuario

La interactividad permite partir de una visión ejecutiva, aislar una ciudad o periodo, y llegar a una explicación específica sin crear reportes separados.

Conclusiones y entregables

Cumplimiento de la Parte 5 del proyecto

Cumplimiento logrado

Se importaron los CSV sintéticos y se modelaron relaciones correctas.
Se creó DimFecha con jerarquía temporal y relaciones activas.
Se implementaron KPI mediante medidas DAX.
Se diseñaron las tres páginas obligatorias.
Se incorporaron slicers, drill-down, drill-through y bookmarks.

Entregables

AndinaRetail.pbix
AndinaRetail_tableros.pdf
Presentación de defensa de la Parte 5

Aporte a la toma de decisiones

La solución permite a la gerencia monitorear desempeño, detectar alertas de margen y priorizar estrategias de retención de clientes.

Guion de cierre sugerido

“El valor del tablero está en que conecta ventas, margen y comportamiento de clientes dentro de una misma lectura gerencial. Esto permite pasar de observar indicadores aislados a tomar decisiones concretas sobre promociones, plazas y retención.”

Duración objetivo de exposición: 5–7 minutos

Conclusiones y Recomendaciones

CONCLUSIONES CLAVE

1 Omnicanalidad digital

El canal digital ya representa el 55.1% de ventas en 2025. Se debe priorizar el presupuesto de TI y marketing digital hacia Web y App.

2 Problema solucionado en Trujillo

Se demostró cuantitativamente que la caída de margen es causada por descuentos excesivos (16.85%) e ineficiencias logísticas.

3 Modelamiento end-to-end exitoso

Los pronósticos del modelo Random Forest alimentan con éxito al optimizador PuLP para una gestión de inventario óptima.

RECOMENDACIONES ESTRATÉGICAS

1 Ajuste operativo en Trujillo

Suspender las políticas de descuento agresivas, alinear al 7% nacional y optimizar el espacio físico del almacén local.

2 CRM y retención focalizada

Priorizar campañas de fidelización masiva a Campeones y lanzar ofertas dirigidas de reactivación a clientes 'En Riesgo'.

3 Implementación del optimizador

Adoptar la política óptima de reabastecimiento (Q) del modelo PuLP, evitando compras de stock innecesario.