

AndinaRetail S.A.C.

GRUPO 04 · INTEGRANTES Y ROLES

Guzmán Neyra, Paulo Renato

Analista Estadístico / Descriptivo

Huerta Firma, Freddy Anthony

Analista de Optimización / BI

Justino Ocmin, Jhamir Valeri

Científico de Datos

Mendoza Meza, Pablo Andrés

Ingeniero de Datos

Rodas Panaifo, Jordan André

Analista de Optimización / BI

Sánchez Saldaña, Sergio Antonio

Líder del Proyecto / Data PM

ENLACE: https://github.com/SergIOSanchez99/proyecto_AndinaRetail_G4.git

Agenda

1

Contexto y Objetivos

Situación de negocio de Andina Retail y alcance de las cinco fases analíticas.

2

Herramientas y Metodología

Ecosistema de desarrollo, control de versiones y uso de IA generativa.

3

Fase 1 — Ingeniería de Datos

Generación, integridad y control de calidad del dataset sintético.

4

Fase 2 y 3 — Análisis Estadístico

Pruebas de hipótesis, series de tiempo, Pareto y segmentación de clientes.

5

Fase 4 — Modelado Predictivo

Regresión de demanda y clasificación de respuesta a campañas.

6

Fase 5 — Optimización Prescriptiva

Formulación matemática (PuLP) y simulación bajo incertidumbre.

7

Conclusiones y Recomendaciones

Hallazgos clave y lineamientos estratégicos para la gerencia.

Contexto de Negocio y Objetivos

CONTEXTO EMPRESARIAL

- 1

Empresa peruana omnicanal

AndinaRetailS.A.C. opera tiendas físicas y canal digital (Web y App) con presencia en Lima, Arequipa, Trujillo, Cusco y Piura.
- 2

Desafíos de rentabilidad

Se detectó una caída atípica de margen en Trujillo desde 2025-Q2 que requiere un diagnóstico causa-raíz urgente.
- 3

Retención y fuga de clientes

La gerencia observa un nivel relevante de inactividad de clientes y requiere segmentación y retención dirigida.

OBJETIVO GENERAL DE LA DEFENSA

- 1

Fase 1 —Ingeniería y calidad de datos

Asegurar consistencia, integridad referencial y control de nulos/outliers en el dataset sintético de ventas.
- 2

Fase 2 y 3 —Análisis estadístico

Pruebas de hipótesis, series de tiempo, Pareto y segmentación RFM + K-Means.
- 3

Fase 4 —Modelado predictivo

Regresión para demanda y clasificación de respuesta a campañas, evitando data leakage.
- 4

Fase 5 —Optimización prescriptiva

Políticas óptimas de reabastecimiento con PuLP, validadas bajo incertidumbre (Monte Carlo).

Herramientas y Ecosistema de Desarrollo

ECOSISTEMA DE DESARROLLO Y CONTROL

- 1 Git & GitHub**
Control de versiones local con Git y alojamiento del repositorio en GitHub, facilitando la colaboración, integración de ramas y respaldo del código.
- 2 JupyterNotebooks y Collab**
Entornos de desarrollo basados en web que permiten estructurar interactivamente las cinco fases del análisis de datos. Su arquitectura por "celdas" facilita la ejecución modular del código, permitiendo depurar y ver resultados al instante sin reiniciar todo el flujo.
- 3 Librerías de código abierto**
pandas/numpy para limpieza de datos, scipy para contraste de hipótesis, scikit-learn/lightgbm para modelado y PuLP para optimización lineal.

METODOLOGÍA E IA GENERATIVA

- 1 IA generativa en el flujo de trabajo**
Co-programación interactiva apoyada en modelos de lenguaje (Claude, ChatGPT, Gemini) para la generación rápida de código base y depuración.
- 2 Bitácora de prompts**
Registro y documentación detallada de cada prompt utilizado, almacenado en docs/bitacora_prompts.md para garantizar reproducibilidad.
- 3 Ingeniería de prompts**
Diseño de instrucciones estructuradas para simular patrones comerciales complejos, evitar fugas de información temporal y calibrar hiperparámetros.

Ingeniería de Datos y Calidad

FLUJO DE DATOS Y GENERACIÓN

- 1** Script generar_datos.py
CódigoPython con semillas fijas (2026) que produce datos coherentes y reproducibles usando Faker (es_PE).
- 2** Volúmenes del ecosistema
Clientes(15k), productos(800–1000), tiendas (12), ventas (~250k líneas) e inventario mensual (~345k–432k snapshots).
- 3** Filtros e integridad
Modelamiento a nivel de ticket y línea de venta, con validación automática de llaves foráneas mediante aserciones en el script.

DIAGNÓSTICO DE CALIDAD DE DATOS

- 1** Tratamiento de nulos (1%–3%)
Campos como método de pago, % de descuento, canal preferido y distrito contienen nulos controlados con patrones validados.
- 2** Detección de outliers
Outliers en cantidad y % de descuento detectados mediante el método IQR y validados sin romper la coherencia matemática.
- 3** Reglas de consistencia
Validación de $\text{monto_total} = \text{cantidad} \times \text{precio} \times (1 - \text{descuento})$ y del balance de inventario ($\text{stock final} = \text{inicial} - \text{ventas} + \text{reabastecimiento}$).

Análisis Estadístico Descriptivo

ESTADÍSTICA DESCRIPTIVA Y OUTLIERS

- 1** Distribuciones sesgadas
monto_total y cantidad presentan distribuciones no normales (skewness del monto = 8.89), habitual en retail por productos de alto valor.
- 2** Filtro de outliers (IQR)
Las transacciones con cantidad o monto atípico corresponden a compras legítimas en Electrohogar, no a errores de registro.
- 3** Consistencia interna
Se confirmó la correlación directa entre descuento y cantidad comprada, y la consistencia de los precios unitarios.

PRUEBA DE HIPÓTESIS: TICKET POR CANAL

- 1** Formulación de hipótesis
H0: ticket promedio igual en Tienda y Web. H1: son diferentes. Evaluada con t-test de Welch por heterocedasticidad (Levene, $p < 0.0001$).
- 2** Rechazo de H0 con alta confianza
Diferencia significativa (Welch $t = -16.67$, $p < 0.000001$): el ticket promedio en Web es mayor.
- 3** Violación del supuesto de normalidad
Shapiro fue rechazado ($p \approx 0$), pero el Teorema del Límite Central y el gran tamaño de muestra ($N > 200k$) sostienen la validez de la inferencia.

S/ 571

TICKET PROMEDIO · WEB

S/ 464

TICKET PROMEDIO · TIENDA

Estacionalidad y Evolución del Canal Digital

ESTACIONALIDAD Y CAMPAÑAS

- 1

Picos mensuales claros

Las ventas agregadas muestran un patrón estacional estable, con picos máximos en julio (Fiestas Patrias) y diciembre (Navidad).
- 2

Crecimiento progresivo

Estabilidad de la línea base en meses normales, con incrementos previsibles año tras año.
- 3

Implicancias de abastecimiento

La concentración de ventas exige planificar reabastecimiento y promociones con al menos 60 días de anticipación.

EVOLUCIÓN DIGITAL VS. FÍSICO


- 1

Penetración del canal digital

Crecimiento sistemático anual (~10 puntos porcentuales de participación por año).
- 2

Hito del año 2025

El canal digital superó por primera vez al físico, con el 55.1% de la venta total.



Pareto y Segmentación de Clientes

CONCENTRACIÓN DE VENTAS (PARETO 80/20)


- 1

Concentración de productos

El 17.8% de los productos (142 de 800) genera el 80% de las ventas; la mayoría pertenece a Electrohogar.
- 2

Amplia base de clientes

El 45.2% de los clientes genera el 80% del valor: no hay dependencia de pocos clientes VIP, la base es democrática.



SEGMENTACIÓN RFM MANUAL

- 1

Segmento Campeones (24.8%)

Clientes de alta frecuencia y gasto, con ticket histórico promedio de S/ 17,645. Motor financiero principal del negocio.
- 2

Riesgo crítico de fuga

El segmento Hibernando/ Perdidos representa el 35.3% de la base, con una recencia promedio de 253 días.
- 3

Clientes 'No Perder' y 'En Riesgo' (4.8%)

Clientes de alto valor histórico pero alta recencia: foco principal de las campañas de CRM.



Validación de Segmentos con K-Means

CLUSTERING NO SUPERVISADO

- 1

Determinación de k óptimo

El método del codo confirmó que k= 4 clusters representa de forma óptima la varianza de los datos RFM estandarizados.
- 2

Validación de la segmentación

La progresión de valores promedio de los clusters (de alto valor a inactivos) coincide matemáticamente con los perfiles del RFM manual.
- 3

Aplicación práctica

Permite automatizar en producción la asignación de ofertas personalizadas según el cluster asignado dinámicamente.
- 4

Consistencia con el RFM manual

Se validó una alta coincidencia operativa: los clusters capturan con precisión a los 'Campeones' y a los 'Hibernando' del RFM manual.

PERFIL DE LOS CLUSTERS OBTENIDOS

Cluster / Perfil	N Clientes	Recencia	Frec.	Gasto Med.
Alto Valor, Activo	2,491	13.7 días	34.7	S/ 21,817
Valor Medio, Activo	4,895	36.4 días	20.8	S/ 9,933
Bajo Valor, Inactivo	6,227	131.4 días	9.1	S/ 3,543
Perdido / Crítico	1,282	504.1 días	3.9	S/ 1,917

- 1


Consistencia estadística

Se validó una alta coincidencia operativa: los clusters capturan con precisión a los 'Campeones' y a los 'Hibernando' del RFM manual.

Causa Raíz: Caída de Margen en Trujillo

IDENTIFICACIÓN DEL PROBLEMA

- 1 **Caída de margen en Trujillo**
A partir de 2025-Q2, el margen en Trujillo se desploma de 24.33% a 13.86% (-10.5 puntos).
- 2 **Estabilidad en otras plazas**
Lima, Cusco, Arequipa y Piura no muestran variación en sus márgenes (~23-24%) en el mismo periodo.
- 3 **Ventas con margen negativo**
De 209 líneas de venta con margen negativo en todo el país, 169 (81%) pertenecen a Trujillo en 2025.



DESCOMPOSICIÓN DE LA CAUSA RAÍZ

- 1 **Incremento del descuento promedio**
En Trujillo el descuento promedio se triplicó, de 5.69% a 16.85%: evidencia de una política comercial agresiva y descontrolada.
- 2 **Incremento de costos logísticos**
El costo de almacenamiento unitario por producto-tienda casi se duplicó, de S/ 0.30 a S/ 0.56, inflando el holding cost.
- 3 **Recomendaciones inmediatas**
Corregir la política de descuentos (alinear a la media de 7%) y optimizar los stocks locales para reducir el holding cost.

16.85%
DESCUENTO PROM. TRUJILLO

S/ 0.56
COSTO ALMACÉN UNITARIO

Caso de Regresión:

Planteamiento

- 1 Problema**
Estimar la demanda mensual futura de cada producto según el canal de venta, la campaña comercial, el periodo y el comportamiento histórico de la demanda y los descuentos.
- 2 Pregunta de negocio:**
¿Cuántas unidades de cada producto se espera vender durante una campaña comercial determinada, en un mes y canal de venta específicos?
- 3 Objetivo general:**
Desarrollar y evaluar modelos predictivos de regresión que permitan estimar la cantidad de unidades demandadas de cada producto por campaña comercial, mes y canal de venta, utilizando las características del producto y el comportamiento histórico de la demanda y los descuentos.
- 4 Variable objetivo:**
Demanda, medida como la cantidad total de unidades vendidas.

Caso de Clasificación:

Planteamiento

- 1 Problema**
Predecir la respuesta de los clientes a una campaña comercial según su comportamiento histórico de compra, el periodo y las características de la campaña.
- 2 Pregunta de negocio:**
¿Un cliente realizará una compra durante una campaña comercial específica, considerando su comportamiento de compra anterior?
- 3 Objetivo general:**
Desarrollar y evaluar modelos predictivos de clasificación que permitan identificar si un cliente realizará una compra durante una campaña comercial determinada, utilizando su comportamiento histórico de compra y la información disponible antes del inicio de la campaña.
- 4 Variable objetivo:**
respuesta_campaña
 - 0 = No respondió a la campaña.
 - 1 = Respondió a la campaña.

Caso de Regresión:

Variable	Tipo	Rol dentro del modelo
nombre	Categórica	Identifica el producto cuya demanda se desea estimar.
categoria	Categórica	Representa la categoría general del producto.
subcategoria	Categórica	Proporciona un nivel más específico de clasificación.
marca	Categórica	Permite identificar diferencias de demanda entre marcas.
canal	Categórica	Indica el canal de venta asociado a la demanda.
campana	Categórica	Identifica la campaña comercial evaluada.
tipo_campana	Categórica	Agrupar la campaña según su tipo comercial.
mes	Categórica	Representa el mes del periodo a predecir.
demanda_mes_anterior	Numérica histórica	Cantidad demandada del producto en el mes anterior.
demanda_misma_campana_año_anterior	Numérica histórica	Demanda registrada en la misma campaña del año anterior.
descuento_promedio_mes_anterior	Numérica histórica	Descuento promedio aplicado durante el mes anterior.
descuento_promedio_misma_campana_año_anterior	Numérica histórica	Descuento promedio aplicado en la misma campaña del año anterior.
demanda	Variable objetivo	Cantidad total de unidades vendidas que el modelo debe predecir.

Caso de clasificación:

Variable	Tipo	Rol dentro del modelo
genero	Categórica	Representa el género registrado del cliente.
ciudad	Categórica	Identifica la ciudad de residencia del cliente.
campana	Categórica	Identifica la campaña comercial que se desea evaluar.
tipo_campana	Categórica	Agrupar la campaña según su tipo comercial.
mes	Categórica	Representa el mes en el que se desarrolla la campaña.
edad	Numérica	Edad del cliente al inicio de la campaña.
antiguedad_cliente_dias	Numérica histórica	Días transcurridos desde el registro del cliente.
tickets_misma_campana_anterior	Numérica histórica	Compras realizadas en la misma campaña del año anterior.
tickets_previos_totales	Numérica histórica	Cantidad total de compras anteriores a la campaña.
campanas_anteriores_con_compra	Numérica histórica	Número de campañas anteriores en las que compró.
tickets_mismo_tipo_campana_previos	Numérica histórica	Compras previas realizadas en campañas del mismo tipo.
recencia_dias	Numérica histórica	Días transcurridos desde la última compra previa.
respuesta_campana	Variable objetivo	Indica si el cliente realizó una compra: 1 = Sí, 0 = No.

Entrenamiento:

Partición de datos:

- 2023 → Historial
- 2024 → Entrenamiento
- 2025 → Prueba

Transformación:

One hot encode

Convertir las variables categóricas en numéricas

StandardScaler

Escalar las variables numéricas a una misma escala (media 0 y varianza 1).

Validación cruzada - Regresión:

- Los folds se organizaron por meses.
- Se utilizaron 4 divisiones temporales.
- Cada validación comprendió los dos meses siguientes al periodo de entrenamiento.
- La métrica principal de selección fue el MAE, orientada a minimizar el error de predicción.

Validación cruzada - Clasificación:

- Los folds se organizaron por ediciones de campañas.
- Se utilizaron 3 divisiones temporales.
- Cada validación comprendió las dos campañas siguientes.
- La métrica principal fue el F1-score, orientada a equilibrar precisión y recall.

Otras configuraciones - Regresión

- Modelos evaluados: Ridge Regression, Árbol de Decisión, Random Forest y XGBoost.
- Métrica de selección: menor MAE promedio.
- Métricas complementarias: RMSE y R^2 .

Otras configuraciones - Clasificación

- Modelos evaluados: Regresión Logística, Árbol de Decisión, Extra Trees y LightGBM.
- Métrica de selección: mayor F1-score promedio.
- Métricas complementarias: Precision, Recall, ROC-AUC

Caso de Regresión:

Validación cruzada:

	modelo	MAE_CV	RMSE_CV	R2_CV	desviacion_MAE	desviacion_RMSE	desviacion_R2
0	Random Forest	3.453652	6.251448	0.345899	0.797476	2.610690	0.126173
1	Decision Tree	3.488761	6.153223	0.328990	0.763364	2.285596	0.185957
2	Ridge Regression	3.489216	5.740031	0.339530	0.601122	1.548246	0.283274
3	XGBoost	3.511960	6.275481	0.342783	0.846314	2.670579	0.129174

Prueba

Métrica	Random Forest
MAE	3.179768
RMSE	5.215714
R²	0.708903
Predicciones negativas	0


Caso de clasificación:

Validación cruzada:

	Modelo	Precision_CV	Recall_CV	F1_CV	ROC_AUC_CV	PR_AUC_CV	Desviacion_F1
0	Extra Trees	0.2413	0.4703	0.3118	0.6556	0.2380	0.1373
1	Regresión Logística	0.2653	0.3178	0.2821	0.6599	0.2455	0.1272
2	Árbol de Decisión	0.1862	0.1813	0.1761	0.5217	0.1537	0.0712
3	LightGBM	0.2275	0.0036	0.0071	0.5917	0.1967	0.0019


Prueba

Métrica	Extra Trees
Precisión	0.340973
Recall	0.246740
F1-Score	0.286302
ROC-AUC	0.698140
PR-AUC	0.287680




Caso de Regresión

Feature Importance:




SHAP:




Caso de Clasificación

Feature Importance:



SHAP:



Modelo Prescriptivo y Optimización

FORMULACIÓN MATEMÁTICA (PULP)

- 1

Variables de decisión

$Q(p,t)$: cantidad de reabastecimiento; $E(p,t)$: stock final (holding); $U(p,t)$: ventas insatisfechas (unmet demand).
- 2

Función objetivo

Minimizar el costo total = holding cost ($h \cdot E$) + penalización por faltantes ($\text{penalty} \cdot U$) + costo de compras ($c \cdot Q$).
- 3

Restricciones clave

Balance de flujo de stock, presupuesto máximo de compras (P_{budget}) y límites de capacidad.

ESCENARIOS Y SIMULACIÓN MONTE CARLO

- 1

Sensibilidad de presupuesto y simulación


El análisis de sensibilidad mostró un costo total constante (S/ 40,768.02) entre presupuestos. Se validó además con 100 escenarios Monte Carlo (demanda Poisson), comparando el LP optimizado frente a una heurística del 10%.
- 2

Ventaja del modelo optimizador

El LP logró un ahorro de ~8% en holding frente a la heurística, manteniendo el nivel de servicio.



Modelo de datos implementado



Tablas principales

FactVentas: líneas de venta por ticket.
FactInventario: stock mensual producto-tienda.
DimClientes, DimProductos y DimTiendas.
DimFecha marcada como tabla calendario.

Relaciones

Cardinalidad 1:* desde dimensiones a hechos.
Filtro cruzado en dirección única.
Fecha relacionada con ventas e inventario.
Sin relaciones directas entre tablas de hechos.

Resultado

El modelo permite filtrar ventas, margen e inventario por tiempo, ciudad, categoría, canal y cliente sin duplicar totales.

Indicadores y medidas DAX

S/ 325.3 M

Ventas Totales

S/ 63.1 M

Margen Total

19.40 %

Margen %

100 mil

Tickets

58.15 %

Tasa de inactividad

Medidas representativas

```
Ventas Totales = SUM(FactVentas[moneto_total])  
  
Margen % = DIVIDE([Margen Total], [Ventas Totales], 0)  
  
Ticket Promedio = DIVIDE([Ventas Totales], [Total Tickets], 0)  
  
Tasa de Inactividad = DIVIDE([Clientes Inactivos], [Total Clientes], 0)
```

Por qué medidas y no columnas estáticas

Se recalculan según filtros de año, ciudad, categoría y canal.
Permiten comparar páginas sin duplicar lógica.
Facilitan control de formatos: moneda, porcentaje y enteros.
Separan el cálculo del diseño visual.


Validación

Antes de diseñar las páginas finales se creó una página temporal de validación para comprobar que las tarjetas reaccionaran a los segmentadores.

Página 1: tablero ejecutivo

Visión general del desempeño comercial y de clientes

Lectura gerencial




Objetivo de la página

Permitir que la gerencia identifique en una sola vista el estado comercial, la rentabilidad y el riesgo de clientes antes de profundizar en análisis específicos.

Alerta ejecutiva

La principal señal de riesgo es la inactividad de clientes. Por ello, las páginas siguientes profundizan en ventas, margen y segmentación.

Página 2: análisis de ventas y margen



Qué responde esta página

¿Dónde se concentran ventas y margen?
¿Qué categorías lideran el resultado?
¿Cómo evolucionan Tienda, Web y App?
¿Qué relación existe entre descuento y margen?

Interacción clave

El marcador “Alerta Trujillo 2025” permite enfocar la lectura en la plaza y periodo donde .se requiere revisar la política de descuentos

Decisión sugerida

Monitorear ciudades con mayor descuento promedio y revisar su impacto en margen porcentual antes de intensificar promociones.

Página 3: clientes, RFM y churn

15 mil

Total clientes

6.3 mil

Clientes activos

8.7 mil

Clientes inactivos

58.15 %

Tasa de inactividad

S/ 21.7 mil

Valor promedio

Segmentos principales

Inactivo: 8,723 clientes.
Regular: 2,616 clientes.
Alto Valor: 2,601 clientes.
Frecuente y Ocasional: menor volumen.

Perfil RFM resumido

Alto Valor
Recencia: 16.9 días
Frecuencia: 14.8 tickets
Valor prom.: S/ 52.9 mil

Inactivo
Recencia: 384.3 días
Frecuencia: 3.9 tickets
Valor prom.: S/ 12.4 mil

Hallazgo de clientes

El segmento inactivo concentra la mayor alerta. Los clientes de Alto Valor tienen menor recencia y mayor frecuencia, por lo que deben preservarse con estrategias de fidelización.

Interactividad implementada

- 1

Segmentadores

Año, ciudad, categoría, canal y campaña para filtrar los KPI y gráficos.
- 2

Drill-down

Jerarquía temporal Año → Trimestre → Mes para analizar evolución.
- 3

Drill-through


Página Detalle_Ciudad para profundizar en una plaza seleccionada.
- 4

Navegación

Navegador de páginas para moverse entre las vistas principales.
- 5

Bookmarks

Vista general y Alerta Trujillo 2025 para acelerar la lectura.



Ejemplo: filtros y vista de ventas

Valor para el usuario

La interactividad permite partir de una visión ejecutiva, aislar una ciudad o periodo, y llegar a una explicación específica sin crear reportes separados.

Conclusiones y entregables

Cumplimiento de la Parte 5 del proyecto

Cumplimiento logrado

- Se importaron los CSV sintéticos y se modelaron relaciones correctas.
- Se creó DimFecha con jerarquía temporal y relaciones activas.
- Se implementaron KPI mediante medidas DAX.
- Se diseñaron las tres páginas obligatorias.
- Se incorporaron slicers, drill-down, drill-through y bookmarks.

Entregables

- AndinaRetail.pbix
- AndinaRetail_tableros.pdf
- Presentación de defensa de la Parte 5

Aporte a la toma de decisiones

La solución permite a la gerencia monitorear desempeño, detectar alertas de margen y priorizar estrategias de retención de clientes.

Guion de cierre sugerido

“El valor del tablero está en que conecta ventas, margen y comportamiento de clientes dentro de una misma lectura gerencial. Esto permite pasar de observar indicadores aislados a tomar decisiones concretas sobre promociones, plazas y retención.”

Duración objetivo de exposición: 5–7 minutos

Conclusiones y Recomendaciones

CONCLUSIONES CLAVE

1 Omnicanalidad digital

El canal digital ya representa el 55.1% de ventas en 2025. Se debe priorizar el presupuesto de TI y marketing digital hacia Web y App.

2 Problema solucionado en Trujillo

Se demostró cuantitativamente que la caída de margen es causada por descuentos excesivos (16.85%) e ineficiencias logísticas.

3 Modelamiento end-to-end exitoso

Los pronósticos del modelo Random Forest alimentan con éxito al optimizador PuLP para una gestión de inventario óptima.

RECOMENDACIONES ESTRATÉGICAS

Ajuste operativo en Trujillo

1

Suspender las políticas de descuento agresivas, alinear al 7% nacional y optimizar el espacio físico del almacén local.

2

CRM y retención focalizada

Priorizar campañas de fidelización masiva a Campeones y lanzar ofertas dirigidas de reactivación a clientes 'En Riesgo'.

3

Implementación del optimizador

Adoptar la política óptima de reabastecimiento (Q) del modelo PuLP, evitando compras de stock innecesario.